Séance 11 Les schémas XML

Personnalisation avancées de l'ODD

Construire une ODD

Procédé de création de la documentation et des spécifications d'un document TEI

Structure

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
  <teiHeader>
    <-- MÉTADONNÉES -->
  </teiHeader>
  <text>
    <body>
      <div1>
        <-- DOCUMENTATION -->
      </div1>
      < div1>
        <schemaSpec ident="mon_ODD">
          <-- SPÉCIFICATIONS -->
        </schemaSpec>
      </div1>
    </body>
  </text>
</TEI>
```

Étapes

- 1) Encoder votre extrait
- 2) Produire une ODD avec ODD by example
- 3) Compléter et restructurer l'ODD avec une documentation et des spécifications
- 4) Produire un fichier Relax NG à partir de l'ODD modifiée
- 5) Produire une sortie HTML de son ODD

Consignes

Votre ODD doit contenir au moins:

- Une introduction de votre projet et ses exploitations possibles
- Une explication du fonctionnement de votre encodage et choix de balises
- Une règle contraignant l'usage d'un attribut et sa ou ses valeurs
- Une règle contraignant l'enchaînement de certains éléments
- Une règle contraignant la valeur d'un attribut ou l'usage d'un élément ou d'un attribut en fonction de son environnement

Bonnes pratiques

- Fichier indenté, propre, commenté au besoin
- Règles de validations ordonnées :
 - Modules en premier et classifiés
 - Règles modifiées plutôt vers le début
 - Règles inchangées de préférence vers la fin
- Ligne de commentaire expliquant la modification effectuée avant chaque règle modifiée

Ressources

Making a Unified ODD

Chapitre TEI sur la documentation

Chapitre TEI sur la spécification

Principaux éléments du module tagdocs

Documentation

code, remarks

Désignation des objets: val, gi, att, tag, ident, altIdent

Description de contenu : <u>valDesc</u>

Exemples: eq, eqXML, exemplum

Description de spécifications: specList, specDesc

Documentation dans les spécifications

gloss, desc

Spécifications

Déclaration de spécification: <u>schemaSpec</u>, <u>elementSpec</u>, <u>classSpec</u>, <u>moduleSpec</u>, etc.

Référence: classRef, macroRef, moduleRef

Règles de contenu: content, sequence, alternate, elementRef, textNode, anyElement, empty

Règles d'attributs: <u>attDef</u> <u>attList</u>, <u>defaultVal</u>, <u>valItem</u>, <u>valList</u>, <u>dataSpec</u>, <u>datatype</u>, <u>dataRef</u>, attRef

Règles d'appartenance : <u>classes</u>, <u>member0f</u>

Règles de validation (schematron): constraintspec

Documentation

Décrire ses choix d'encodage

Structure

```
< div1>
  <head>Titre de section</head>
   Explication sur la section
   < div2 >
     <head>Titre de sous-section</head>
     Explication sur la sous-section
     < div3>
         <head>Titre de sous-sous-section</head>
         Explication sur la sous-sous-section
     </div3>
  </div2>
  <div2>[...]</div2>
</div1>
```

La documentation est placé dans une première <div1> est est structurée avec des éléments div allant jusqu'à <div4>. Chaque section est titrée avec un élément <head>.

Résultat de la transformation HTML

Table of contents

- 1. <u>Guide de l'encodage de l'édition numérique de la "Vie de saint Sixte", extrait des Vies de Saints</u> issues du recueil manuscrit 412 de la Bibliothèque nationale de France
 - 1.1. Structure du fichier XML
 - 1.1.1. Structure du teiHeader
 - 1.1.1.1. Le fileDesc
 - 1.1.1.1. Les éléments titleStmt, editionStmt, publicationStmt
 - 1.1.1.1.2. Le sourceDesc
 - 1.1.1.2. <u>Le profileDesc</u>
 - 1.1.2. Structure du texte
 - 1.1.2.1. Reproduction de la structure de la page
 - 1.1.2.2. Encodage des prises de paroles
 - 1.2. Transcription du manuscrit
 - 1.2.1. Régularisations et corrections orthographiques
 - 1.2.1.1. Accentuation
 - 1.2.1.2. Majuscules et différenciation des "u" et "i"
 - 1.2.1.3. Abbréviations et caractères spéciaux
 - 1.2.1.4. Orthographe fautive
 - 1.2.2. Modernisation de la ponctuation
 - 1.2.3. Encodage des spécificités de l'écriture
 - 1.2.3.1. Initiales ornées
 - 1.2.3.2. Autres particularités d'écriture
 - 1.2.4. Difficultés de transcription
 - 1.2.5. Encodage sémantique au sein du texte édité
 - 1.2.5.1. Balisage des noms de personnages et de lieux
 - 1.2.5.2. Identification des locuteurs
 - 1.3. Transformation en fac-similé interactif
- 2. Tableau des éléments

Désigner des éléments

La documentation est rédigée en prose courante mais les objets qu'elle mentionne sont balisés :

- gi Mention d'un élément
- att Mention d'un attribut
- val Mention d'une valeur d'attribut

Lister des éléments

Donner des exemples

Les exemples sont placés dans des balises <egXML> avec l'espace de nom "http://www.tei-c.org/ns/Examples". Toute sorte d'exemples illustratifs peuvent être fournis dans le corps du texte avec <eg>.

Exercice

Ajouter un exemple à sa documentation

Consigne

- Générer une ODD pour Le_Misanthrope_TEI.xml
- Créer une documentation minimale avec au moins un exemple
- Générer la documentation HTML avec la transformation TEI P5 XHTML

Résultat de la transformation HTML

Ainsi, le neuf tironien est ainsi développé :

```
<choice>
  <abbr>9</abbr>
  <expan>con</expan>
  </choice>sellié
```

Spécifications

Définir des règles de validation

Structure

```
< div1>
   <schemaSpec>
      <!-- Déclaration des modules utilisés ou non -->
      <moduleRef key="tei"/>
      <!-- Personnalisation des éléments -->
      <elementSpec>
          <constraintSpec>
              <!-- Règle de validation du contenu -->
          </constraintSpec>
          <attlist>
              <!-- Règle de validation des attributs-->
          </attList>
      </elementSpec>
      <classSpec>
          <!-- Personnalisation des classes -->
      </classSpec>
      <classRef>
          <!-- Classe à inclure -->
      </classRef>
   </schemaSpec>
</div1>
```

Modificationspossibles

Type

Suppression Ajout Modification Remplacement

Objet

Éléments Modèles de contenu Attributs autorisés Valeurs d'attribut Classes

Quelques déclarations disponibles

moduleSpec

Documente la structure, le contenu et les fonctions d'un module

moduleRef

Référence un module qui doit être incorporé dans un schéma

elementSpec

Documente la structure, le contenu et l'usage d'un élément

classSpec

Documente le contenu d'une classe d'attribut ou d'un modèle de classe

Suppression d'un élément

La suppression d'élément est une *clean modification* sauf si c'est élément obligatoire en TEI (<teiHeader> ou tous les éléments de type personLike alors que listPerson> est autorisé)

1) Suppression simple d'un élément avec @mode="delete"

```
<elementSpec ident="head" mode="delete"/>
```

2) Suppression d'élément ou classe dans un module avec @except

```
<moduleRef key="core" except="head"/>
```

3) Non insertion dans un module ou une classe avec @include

```
<moduleRef key="core" include="p author head"/>
```

Ajout d'un élément

L'ajout d'élément n'est pas une pratique recommandée puisqu'elle ajoute au *namespace* TEI.

1) Ajout d'un élément avec @mode="add"

2) Déclaration d'un élément dans le <moduleRef> avec @include

```
<moduleRef key="textstructure" include="alexandrin"/>
```

Modification d'un élément

La modification d'un élément peut porter sur son contenu :

- contrainte d'enchaînement d'éléments précis
- typage des données permises
- attributs autorisés
- valeurs d'attribut valides

Modification d'un élément avec @mode="change"

```
<elementSpec ident="lg" mode="change">
    [...]
</elementSpec>
```

Suppression d'attribut

Ajout d'attribut

Restriction des valeurs d'attribut

```
<elementSpec ident="lg" mode="change">
    <attList>
        <attDef ident="type" mode="change">
            <valList mode="add" type="closed">
                <valItem ident="quatrain"/>
                <valItem ident="sizain"/>
                <valItem ident="sonnet"/>
                <valItem ident="tercet"/>
            </vallist>
        </attDef>
    </attList>
</elementSpec>
```

Exercice

Ajouter un attribut et définir ses valeurs

Consigne

- Créer une ODD pour sonnetTEI.xml
- Déclarer dans l'ODD du texte de Verlaine un attribut "rime" (non TEI) pour l'élément <1>
- Créer une liste de valeurs close : "rime A | rime B | rime C"
- Transformer en .rng
- Associer à l'encodage TEI

Typage de valeurs d'attribut

Typage avec datatype et son enfant dataRef avec l'attribut @key si on pointe vers un <u>type de données défini par la TEI</u> (@name pour XML schéma ou RelaxNG):

```
<attList>
   <attDef ident="type" mode="change">
      <desc xml:lang="fr">
         L'attribut @next doit contenir une
         référence à un xml:id
      </desc>
      <datatype>
         <dataRef key="teidata.pointer"/>
      </datatype>
   </attDef>
</attList>
```

Occurrence des valeurs d'attribut

La valeur par défaut de @minOccurs et @maxOccurs est de 1 et peut avoir pour valeur un_entier_positif | "unbounded" :

```
<attList>
   <attDef ident="type" mode="change">
      <desc xml:lang="fr">
         L'attribut @next doit contenir une
         ou plusieurs références à un xml:id
      </desc>
      <datatype minOccurs="1" maxOccurs="unbounded">
         <dataRef key="teidata.pointer"/>
      </datatype>
   </attDef>
</attList>
```

Statut des valeurs d'attribut

La valeur par défaut de @usage est "opt" (optionnelle) et elle peut prendre pour valeur "rec" (recommandée) ou "req" (requise) :

```
<attList>
   <attDef ident="next" mode="change" usage="req">
      <desc xml:lang="fr">
         L'attribut @next est obligatoire et doit
         contenir une référence à un xml:id
      </desc>
      <datatype>
         <dataRef key="teidata.pointer"/>
      </datatype>
   </attDef>
</attList>
```

Exercice

Restreindre les valeurs des attributs

Consigne

- Reprendre l'ODD pour sonnetTEI.xml
- Typer la valeur d'un attribut
- Limiter les occurrences d'un attribut
- Déclarer un attribut obligatoire
- Transformer en .rng
- Associer à l'encodage TEI

Documenter un élément/attribut

Il est possible de donner des informations supplémentaires sur un élément ou attribut dans les spécifications :

gloss Désignation comme on pourrait la trouver dans un glossaire

desc Définition de l'usage de l'objet et de son contenu

Exercice

Documenter une spécification d'élément

Consigne

- Reprendre l'ODD Le_Misanthrope_TEI.xml
- Ajouter <gloss> et <desc> à un <elementSpec>
- Ajouter <gloss> et <desc> à un <attDef>
- Générer la documentation HTML avec la transformation TEI P5 XHTML

Résultat de la transformation HTML



Description du manuscrit

contient les détails concernant le manuscrit à l'origine de l'encodage : ses identifiants (msIdentifier), son titre (head), son contenu (msContents), sa description matérielle (physDesc) et son histoire (history).

@ corresp	
@ next	
@ ana	
@ facs	
@ resp	
@ source	
@ type	

Définir une séquence de contenu

<content> apparaît toujours avant <attList> dans l'<elementSpec> :
il peut contenir un élément <sequence> qui définit un enchaînement
d'élément. Son attribut @preserveOrder permet de spécifier si l'ordre
de déclaration est signifiant

```
<elementSpec ident="div" mode="change">
   <content>
      <sequence preserveOrder="true">
        <elementRef key="head" min0ccurs="1"</pre>
                     maxOccurs="1"/>
        <elementRef key="p" min0ccurs="1"</pre>
                     maxOccurs="unbounded"/>
     </sequence>
  </content>
</elementSpec>
```

Définir un contenu textuel

```
<elementSpec ident="div" mode="change">
   <content>
      <sequence>
        <textNode/>
        <elementRef key="persName"/>
     </sequence>
  </content>
</elementSpec>
<elementSpec ident="p" mode="change">
   <content>
      <textNode/>
  </content>
</elementSpec>
```

Définir une alternance de contenu

```
<elementSpec ident="choice" mode="change">
   <content>
      <alternate>
         <sequence>
            <elementRef key="sic"/>
            <elementRef key="corr"/>
         </sequence>
         <sequence>
            <elementRef key="orig"/>
            <elementRef key="reg"/>
         </sequence>
      </alternate>
   </content>
</elementSpec>
```

Règles de validation

La syntaxe Schematron

Règle schematron et namespace

Les règles schematron n'utilisent pas le même *namespace* que le reste de l'ODD qui utilise l'espace de nom TEI : il faut donc déclarer un @xmlns dans l'élément racine et préfixer les règles schematron.

Les chemins renseignés dans la règle schematron doivent être préfixés avec le *namespace* tei.

```
<TEI xmlns="http://www.tei-c.org/ns/1.0"
    xmlns:s="http://purl.oclc.org/dsdl/schematron">
    [...]
    <s:assert test="tei:div">[...]</s:assert>
</TEI>
```

Contraindre un élément

La règle est contenue dans un élément < constraint Spec>. Le langage utilisé est déclaré dans l'attribut @scheme et la règle est nommée à l'aide de l'attribut @ident.

<s:assert> permet de définir un test à respecter en <u>Xpath</u> ainsi qu'un message d'erreur à afficher si la contrainte n'est pas respectée

Ajouter du contexte

<s:rule> permet d'ajouter un contexte à l'application à <s:assert>

```
<constraintSpec ident="subDiv" scheme="schematron">
   <constraint>
      <s:rule context="tei:div">
         <s:assert test="count(tei:div)!= 1">
            Si elle contient des subdivisions,
            une division doit en contenir
            au moins deux
         </s:assert>
      </s:rule>
   </constraint>
</constraintSpec>
```

Contraindre l'existence

Contraindre l'activation d'un élément ou d'un attribut en fonction d'un contexte donné

Contraindre le contenu

Contraindre le type de contenu d'une valeur d'attribut

```
<constraintSpec ident="fromVal" scheme="schematron">
   <constraint>
      <s:rule context="tei:app[@from]">
         <s:assert test="matches(@from, '^#w\d+$')">
            L'attribut @from doit contenir une
            valeur qui commence par #w et finit
            par un nombre
         </s:assert>
      </s:rule>
   </constraint>
</constraintSpec>
```

Exercice

Rédiger des règles schematron

Consigne

- Reprendre l'ODD pour sonnetTEI.xml
- Rendre obligatoire la présence d'un ou plusieurs vers
- Un <lg type="sonnet"> doit commencer par un titre
- Paramétrer les <1g type="sonnet"> de telle sorte à ce qu'il contiennent deux quatrain et un sizain
- Écrire une règle schematron pour que les valeurs @n de <l> se suivent :
 number(@n) = number(preceding-sibling::tei:l[1]/@n) + 1
 Attention, il y a un piège
- Générer le schéma RelaxNG et l'associer au fichier TEI